


# Le générateur de *scanners* (F)LEX



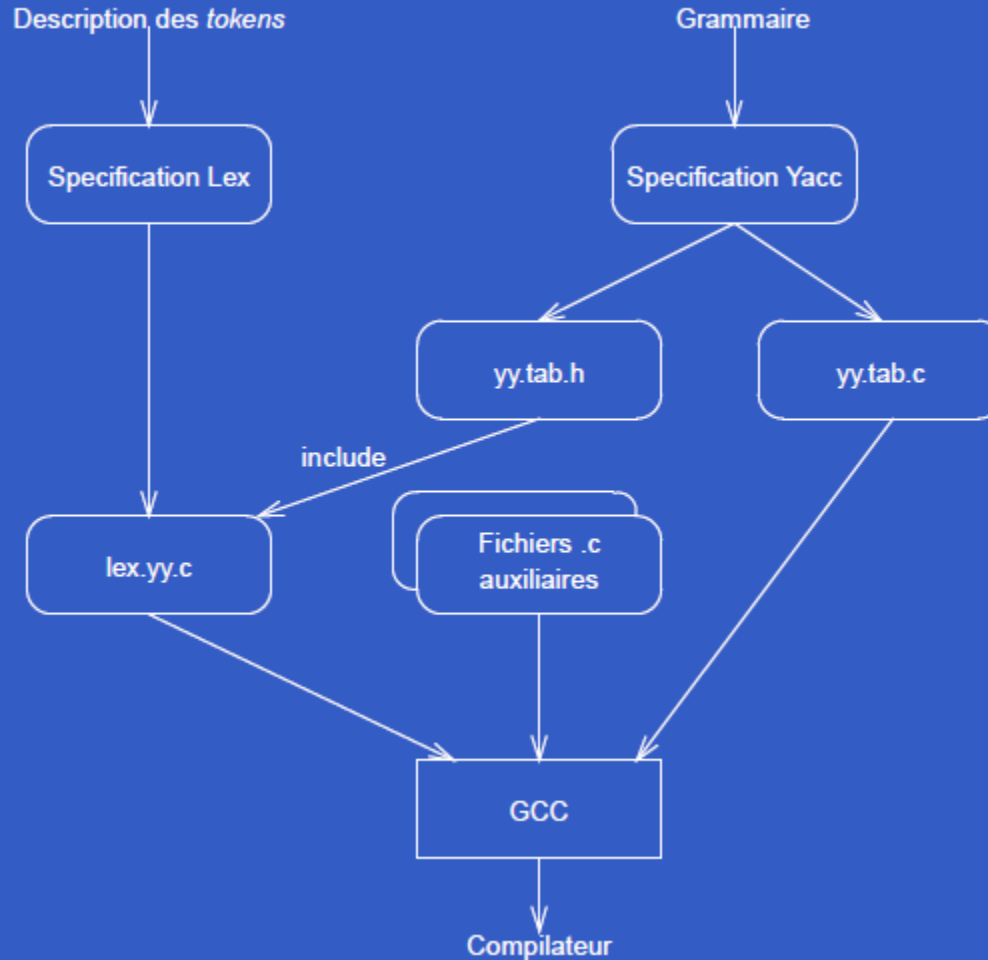
# Introduction – 1

- LEX est un outil qui permet de **générer automatiquement** un *scanner* à partir d'une **spécification**.
- Il est souvent utilisé en conjonction avec YACC (générateur d'analyseur syntaxique), qui fera l'objet d'un prochain TP...
- Il existe une version GNU de LEX, qui s'appelle FLEX, ainsi que de YACC, qui s'appelle BISON.

# Introduction – 2

- L'*input* de LEX est une **spécification**, formée de paires d'expressions régulières et de code C ;
- LEX s'en sert pour générer un fichier source C, implémentant le *scanner* sous la forme d'une **fonction** : `yylex()` ;
- L'exécutable, obtenu après compilation, analyse son *input* pour trouver des **occurrences des expressions régulières** de la spécification, et **exécute le code C** associé.

# Interaction LEX-YACC



# Format d'une spécification LEX

- Format en trois parties, séparées par des %% :
- **Partie 1** : Déclaration de variables, de constantes et de définitions régulières ;
  - Les définitions régulières sont utilisées comme des « macros » dans les actions ;
  - Par exemple : `chiffre [0-9]`

# Format d'une spécification LEX

- Format en trois parties, séparées par des %% :
- **Partie 2** : Règles de traduction, de la forme :  
$$\text{ExpReg} \quad \{ \text{Action} \}$$
  - ExpReg est une **expression régulière étendue** ;
  - Action est un **fragment de code C**, qui sera exécuté chaque fois qu'un *token* satisfaisant ExpReg est rencontré.
  - Les actions peuvent faire appel aux expressions régulières de la partie 1 grâce aux { } ;
  - Par exemple : {chiffre} {Action...} ;

# Format d'une spécification LEX

- Format en trois parties, séparées par des %% :
- **Partie 3** : Procédures de l'utilisateur.
  - Par exemple : `main()` si le *scanner* n'est pas utilisé avec YACC ou BISON.

# Variables spéciales accessibles

- Dans les **actions**, on peut accéder à certaines variables spéciales :
  - `yylen` : contient la **taille** du *token* reconnu ;
  - `yytext` : est une variable de type `char*` qui pointe vers la **chaîne de caractères reconnue** par l'expression régulière.
  - `yyval` : qui permet de **passer des valeurs entières** à YACC...
- Il existe aussi une action spéciale : **ECHO** qui équivaut à `printf ("%s", yytext)`.



# Exemple

```
chiffre [0-9]
lettre [a-z] | [A-Z]
%%
{lettre}({chiffre}|{lettre})*    {
    printf("J'ai reconnu l'identifiant:
    %s de longueur %d\n", yytext, yyleng) ;
}

({chiffre})+    {
    printf("J'ai reconnu un nombre\n") ; ECHO ;
}

%%
main() { yylex() ; }
```